

Proyecto: Clasificación de textos

Leonardo Flores Torres

8 de enero de 2023

Reunir un conjunto de 15 documentos de 5 clases. Cada documento de al menos 1 página. Seleccionar 10 documentos de cada clase aleatoriamente para realizar el entrenamiento bajo el esquema de bolsa de palabras.

- Emplear los 5 documentos restantes de cada clase para clasificar empleando el teorema de Bayes.
- Resumir sus resultados empleando una matriz de confusión.
- Calcular métricas TP, TN, FP, FN por clase, y también calcular Accuracy, Precision, Recall, Specificity, y F1-Score por clase.
- Discutir los resultados obtenidos.

Todos los libros usados para este trabajo fueron obtenidos de la plataforma gratuita de libros Project Gutenberg¹, en la cual los libros están clasificados por categorías las cuales fueron usadas como los nombres de los directorios en donde se almacenaron los libros. A continuación se muestra un listado de los libros usados para el conjunto de entrenamiento guardados en el directorio `training-dataset`:

```
› exa --tree -L=2 train-dataset/  
training-dataset  
├── biology  
│   ├── an-elementary-study-of-insects.txt  
│   ├── concerning-animals-and-other-matters.txt  
│   ├── contributions-to-the-theory-of-natural-selection.txt  
│   ├── life-history-of-the-kangaroo-rat.txt  
│   ├── the-origin-of-species.txt  
│   └── the-story-of-the-living-machine.txt  
├── chemistry  
│   ├── elements-of-chemistry.txt  
│   ├── on-laboratory-arts.txt  
│   ├── on-the-antiquity-of-the-chemical-art.txt  
│   ├── the-chemical-history-of-a-candle.txt  
│   ├── the-history-of-phosphorus.txt  
│   └── the-story-of-alchemy-and-the-beginnings-of-chemistry.txt  
└── fiction  
    ├── a-little-journey.txt  
    ├── alices-adventures-in-wonderland.txt  
    └── around-the-world-in-eighty-days.txt
```

¹<https://www.gutenberg.org/>

```

|— in-the-year-2889.txt
|— the-adventures-of-sherlock-holmes.txt
|— the-great-gatsby.txt
|— the-scarlet-letter.txt
|— the-world-set-free.txt
|— horror
|— dracula.txt
|— metamorphosis.txt
|— scotish-ghost-stories.txt
|— the-call-of-cthulhu.txt
|— the-dunchich-horror.txt
|— the-legend-of-sleepy-hollow.txt
|— the-mysteries-of-udolpho.txt
|— music
|— contemporary-american-composers.txt
|— essentials-in-conducting.txt
|— for-every-music-lover.txt
|— how-to-sing.txt
|— life-of-chopin.txt
|— poetry
|— men-and-women.txt
|— poems-by-walt-whitman.txt
|— the-new-morning-poems.txt
|— the-rime-of-the-ancient-mariner.txt
|— the-waste-land.txt
|— the-works-of-horace.txt
|— underwoods.txt
|— violets-and-other-odes.txt
|— politics
|— a-preface-to-politics.txt
|— anarchism-and-other-essays.txt
|— political-ideals.txt
|— the-communist-manifesto.txt
|— utopia.txt

```

La selección aleatoria de libros fue confusa de implementar, en vez de eso se descargaron más libros pertenecientes a las mismas categorías de los mostrados anteriormente guardados en una carpeta llamada `test-dataset` :

```

> exa --tree -L=2 test-dataset/
test-dataset
|— biology
|— evolution-old-and-new.txt
|— the-dancing-mouse.txt
|— chemistry
|— an-elementary-study-of-chemistry.txt
|— the-sceotical-chymist.txt
|— fiction
|— the-lost-king-of-oz.txt
|— horror
|— the-great-god-pan.txt

```

```
├── the-wendigo.txt
├── music
│   └── musical-memories.txt
├── poetry
│   ├── poems-of-sidney-lanier.txt
│   └── the-complete-poems-of-sir-thomas-moore.txt
└── politics
    ├── leviathan.txt
    └── the-prince.txt
```

Del resultado de la terminal se puede observar que las categorías elegidas fueron las siguientes

- "chemistry",
- "poetry",
- "fiction",
- "biology",
- "horror",
- "music",
- "politics".

Este trabajo fue realizado usando el lenguaje de programación `python`. Este contiene ya muchas librerías con las funcionalidades que se podrían llegar a necesitar para cumplir con los puntos requeridos. Primero se cargan las librerías necesarias:

```
1  import pathlib    # To handle files
2  import numpy as np    # To handle arrays as numpy arrays
3  import matplotlib.pyplot as plt    # For plotting purposes
4
5  from sklearn.feature_extraction.text import CountVectorizer
6  from sklearn.model_selection import train_test_split
7  from sklearn.naive_bayes import MultinomialNB
8  from sklearn.metrics import accuracy_score
9  from sklearn.metrics import confusion_matrix
10 from sklearn.metrics import classification_report
```

Posteriormente se deben definir los directorios en donde se encuentran los conjuntos de entrenamiento y de prueba, respectivamente:

```
11 working_dir = pathlib.Path().absolute()
12 train_dir = working_dir / "training-dataset/"
13 test_dir = working_dir / "test-dataset/"
```

Para encontrar las categorías presentes en estos directorios se escribió la siguiente función:

```

14 def get_categories_paths(files_dir):
15     paths = []
16     for item in files_dir.iterdir():
17         if item.is_dir():
18             paths.append(item)
19
20     return paths

```

En realidad no se obtienen las categorías sino el `path` de los directorios con cuyos nombres corresponden a las categorías, por ejemplo:

```

1  # REPL
2
3  >>> categories_paths = get_categories_paths(train_dir)
4  >>> categories_paths
5  [PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-
6  ↪ dataset/chemistry'),
7  PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-dataset/poetry'),
8  PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-dataset/fiction'),
9  PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-dataset/biology'),
10 PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-dataset/horror'),
11 PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-dataset/music'),
12 PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-dataset/politics')]

```

Posteriormente, de estos `path`s se extraen los últimos elementos de cada cadena para convertirlos en diccionarios y poder acceder a ellos de acuerdo a una palabra clave la cual, si es usada con el diccionario,

```

21 def get_categories(files_dir):
22     categories_paths = get_categories_paths(files_dir)
23     categories = dict()
24     for path in categories_paths:
25         category = path.as_posix().split("/")[-1]
26         categories[category] = path
27
28     return categories

```

El siguiente ejemplo es una llamada a la función `get_categories` con el `path` del conjunto de entrenamiento:

```

1  # REPL
2
3  >>> categories = get_categories(train_dir)
4  >>> categories
5  {'chemistry': PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-
6  ↪ dataset/chemistry'),
7  'poetry': PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-
8  ↪ dataset/poetry'),
9  'fiction': PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-
10 ↪ dataset/fiction'),
11 'biology': PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-
12 ↪ dataset/biology'),

```

```

8  'horror': PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-
   ↳ dataset/horror'),
9  'music':
   ↳ PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-dataset/music'),
10 'politics': PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-
   ↳ dataset/politics')}}
11
12 >>> categories["horror"]
PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-dataset/horror')

```

Todavía es necesario listar de alguna manera los libros presentes por categoría, lo que es lo mismo, listar los archivos dentro de uno de los directorios de las categorías indicadas anteriormente:

```

29 def get_books_in_category(category_path):
30     books_in_category = []
31     for item in category_path.iterdir():
32         if item.is_file():
33             books_in_category.append(item)
34
35     return books_in_category

```

Si únicamente se quisiera listar los libros dentro de la categoría "horror" se haría de la siguiente manera:

```

1  # REPL
2
3  >>> books_in_horror = get_books_in_category(categories["horror"])
4  >>> books_in_horror
5  [PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-
   ↳ dataset/horror/metamorphosis.txt'),
6   PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-dataset/horror/the-
   ↳ dunchich-horror.txt'),
7   PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-dataset/horror/the-
   ↳ legend-of-sleepy-hollow.txt'),
8   PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-dataset/horror/the-
   ↳ mysteries-of-udolpho.txt'),
9   PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-
   ↳ dataset/horror/dracula.txt'),
10  PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-dataset/horror/the-
   ↳ call-of-cthulhu.txt'),
11  PosixPath('/home/leo/Documents/mia/mia-activities/mia-2022-half2/mp/mp-proyecto/training-
   ↳ dataset/horror/scotish-ghost-stories.txt')]

```

Aunque listar los libros en una sola categoría no es de gran utilidad ya que se requieren de los libros en todas las categorías de libros. Pero antes de llegar a ese punto se definió una función que pueda el texto de un libro seguida de otra función que lea todos los textos en una categoría:

```

35 def get_text_of_book(book):
36     with open(book, "r", encoding="utf-8") as file:
37         for string in file:

```

```
38         book_text = file.read().replace("\n", "")
39
40     return book_text
41
42 def get_all_texts_in_category(category):
43     books_in_category = get_books_in_category(category)
44
45     return list(map(get_text_of_book, books_in_category))
```

Estas funciones son útiles por sí solas pero lo hecho hasta ahora ha sido para poder escribir una función extra que permita generar todo el conjunto de entrenamiento, esto es, leer todos los libros y tenerlos disponibles por categorías:

```
43 def get_training_data(files_dir):
44     categories = get_categories(files_dir)
45     corpus = []
46     labels = []
47     for key in categories.keys():
48         texts_in_category = get_all_texts_in_category(categories[key])
49         texts_labels = [key] * len(texts_in_category)
50         corpus += texts_in_category
51         labels += texts_labels
52
53     return corpus, labels
```

Ejemplo de lo anteriormente mencionado se muestra a continuación mostrando las categorías de los libros en el conjunto de entrenamiento:

```
1  # REPL
2
3  >>> corpus_train, label_train = get_training_data(train_dir)
4  >>> label_train
5  ['chemistry',
6   'chemistry',
7   'chemistry',
8   'chemistry',
9   'chemistry',
10  'poetry',
11  'poetry',
12  'poetry',
13  'poetry',
14  'poetry',
15  'poetry',
16  'poetry',
17  'poetry',
18  'fiction',
19  'fiction',
20  'fiction',
21  'fiction',
22  'fiction',
```

```
23 'fiction',
24 'fiction',
25 'fiction',
26 'biology',
27 'biology',
28 'biology',
29 'biology',
30 'biology',
31 'biology',
32 'horror',
33 'horror',
34 'horror',
35 'horror',
36 'horror',
37 'horror',
38 'horror',
39 'music',
40 'music',
41 'music',
42 'music',
43 'music',
44 'politics',
45 'politics',
46 'politics',
47 'politics',
48 'politics']
```

De igual manera, la función `get_training_data`² no solamente permite leer los libros de entrenamiento sino tambien libros en otro directorio que cumplan con la misma estructura a la ya mencionada hasta ahora. De esta manera, se podría leer otro directorio donde se encuentre el conjunto de libros para probar el modelo. El directorio que contiene el conjunto de prueba está definido en `test_dir`:

```
1 # REPL
2
3 >>> corpus_test, label_test = get_training_data(test_dir)
4 >>> label_test
5 ['chemistry',
6  'chemistry',
7  'poetry',
8  'poetry',
9  'fiction',
10 'biology',
11 'biology',
12 'horror',
13 'horror',
14 'music',
15 'politics',
16 'politics']
```

²La elección del nombre de la función es un poco desafortunada ya que claramente indica que solo funciona para leer los libros del conjunto de entrenamiento.

Habiendo leído los libros en ambos conjuntos se generan la bolsa de palabras a partir del conjunto de entrenamiento y se computa la frecuencia de las palabras para cada texto del conjunto de prueba respecto a las palabras en la bolsa de palabras computada del conjunto de entrenamiento:

```

1  # REPL

2  # Bolsa de palabras a partir del conjunto de entrenamiento
3  >>> vectorizer = CountVectorizer(tokenizer=str.split, stop_words="english")
4  >>> corpus_train_mat = vectorizer.fit_transform(corpus_train)
5  >>> corpus_train_mat = corpus_train_mat.toarray()

6  # Computa la frecuencia de las palabras para cada texto en el conjunto de prueba respecto a la bolsa de
   ↪ palabras
7  >>> corpus_test_mat = vectorizer.transform(corpus_test)
8  >>> corpus_test_mat = corpus_test_mat.toarray()

```

Ahora se debe aplicar la clasificación de los textos a partir del método de Naive Bayes, pero primero hay que generar el modelo a partir de la bolsa de palabras y las categorías identificadas para cada libro. La siguiente función se encarga de generar el modelo con los datos de entrenamiento:

```

53 def naive_bayes(train_set, train_label):
54     model = MultinomialNB()
55     model.fit(train_set, train_label)
56
57     return nbclassifier

```

Se pasan los datos de entrenamiento a la función `naive_bayes` para entrenar el modelo y se realiza la prueba con el conjunto de libros de prueba:

```

1  # REPL

2  # Generar el modelo
3  >>> nb_model = naive_bayes(corpus_train_mat, label_train)

4  # Probar el modelo
5  >>> label_predicted = nb_model.predict(corpus_test_mat)
6  >>> label_predicted
7  array(['chemistry', 'chemistry', 'poetry', 'poetry', 'fiction', 'biology',
8        'chemistry', 'horror', 'horror', 'music', 'politics', 'horror'],
9        dtype='<U9')

```

¿Pero cómo se comparan las categorías verdaderas respecto a las predicciones? Se puede ver rápidamente cuáles libros han sido mal categorizados. La siguiente función toma las listas de ambas categorías y las muestra en una lista para una fácil comparación:

```

57 def comparisson(test_label, predicted_label):
58     print("Real \t | Predicted")
59     print("-----")

```



```

60     for pair in zip(test_label, predicted_label):
61         print(pair[0] + " \t | " + pair[1])

```

La llamada de la función anterior `comparisson` con las categorías originales y las predichas de los libros en el conjunto de prueba se muestra a continuación:

```

1  # REPL
2  >>> comparisson(label_test, label_predicted)
3  Real          | Predicted
4  -----
5  chemistry     | chemistry
6  chemistry     | chemistry
7  poetry        | poetry
8  poetry        | poetry
9  fiction        | fiction
10 biology       | biology
11 biology       | chemistry    # Error en clasificacion
12 horror        | horror
13 horror        | horror
14 music         | music
15 politics      | politics
16 politics      | horror       # Error en clasificacion

```

Para finalizar, se escribió una última función para generar la matriz de confusión

```

62 def get_confusion_matrix(train_label, test_label, predicted_label):
63     conf_mat = confusion_matrix(test_label, predicted_label)
64     labels = sorted(set(train_label))
65
66     plt.figure()
67     plt.title("Matriz de confusión")
68     plt.imshow(conf_mat, interpolation="nearest", cmap=plt.cm.PuBu)
69     plt.xticks(np.arange(len(labels)), labels, rotation=45)
70     plt.yticks(np.arange(len(labels)), labels)
71     plt.xlabel("Categoría predicha")
72     plt.ylabel("Categoría verdadera")
73     plt.colorbar()
74     plt.show()

```

Simplemente se llama con las categorías de entrenamiento, de prueba y las predichas como se muestra a continuación:

```

1  # REPL
2  >>> get_confusion_matrix(label_train, label_test, label_predicted)

```

Los resultados a las métricas TP, TN, FP, FN son las mostradas en la matriz de confusión, mientras que los resultados para el resto de las métricas pendientes son mostrados a continuación:




Figura 1: Matriz de confusión.

```

1  # REPL
2  >>> print(classification_report(label_test, label_predicted, zero_division=0))
3
4      precision    recall  f1-score   support
5
6  biology          1.00      0.50      0.67         2
7  chemistry        0.67      1.00      0.80         2
8  fiction           1.00      1.00      1.00         1
9  horror           0.67      1.00      0.80         2
10 music            1.00      1.00      1.00         1
11 poetry           1.00      1.00      1.00         2
12 politics          1.00      0.50      0.67         2
13
14 accuracy          0.83
15 macro avg         0.86
16 weighted avg      0.82

```

De la matriz de confusión en la figura 1 se puede observar que hay dos libros que están mal clasificados. Esto se puede verificar al observar la comparación en la tabla mostrada anteriormente donde se listaron las categorías reales y las predichas. Uno de los libros en la categoría de biología fue mal clasificado en la categoría de química, mientras que un libro de política se clasificó dentro de la categoría de horror.

Al inicio de este estudio se notó que la cantidad de libros requerida para este trabajo era poca, esto se vio reflejado en la pobre clasificación de los textos, y por ello se decidió incluir más categorías con más libros por categoría. El número de libros por categoría que se muestra al inicio del trabajo en el desglose dependió de en qué punto

comenzaban a mejorar las predicciones. Se esperaba que con mayor diversidad de categorías, siendo éstas menos similares las unas con las otras, se obtuviera como resultado una mejor clasificación.

Uno de los primeros intentos al escribir este trabajo se realizó incluyendo a la categoría de ficción y a la de horror, con política y cuentos infantiles, con 5 libros por categoría. Resultó en una pobre clasificación ya que los libros elegidos influían fuertemente en la clasificación. La ficción es un género literario bastante general, este género tiene muchos subgéneros. A pesar de no ser iguales, la ficción al horror, son similares, y eso hace que la elección de libros importe en este caso. Algo similar sucedió con los libros elegidos inicialmente para la categoría de cuentos infantiles.

Con los ajustes pertinentes, y una selección más detallada de los libros respecto a sus categorías, se logró que la mayoría de los libros en el conjunto de prueba fuesen clasificados correctamente. Una de las razones por las cuales uno de los libros en la categoría de biología fuese reconocido como perteneciente a la categoría de química es porque en ambas áreas de las ciencias suelen tener vocabulario técnico y no técnico similar ya que están fuertemente relacionadas.

Referencias

- [1] Simon JD Prince. *Computer vision: models, learning, and inference*. Cambridge University Press, 2012.
- [2] Jeff Bezanson, Alan Edelman, Stefan Karpinski, and Viral B. Shah. Julia: A fresh approach to numerical computing. *SIAM Review*, 59(1):65–98, 9 2017.
- [3] Ritchie Ng. Vectorization, multinomial naive bayes classifier and evaluation. <https://www.ritchieng.com/machine-learning-multinomial-naive-bayes-vectorization/>. Visitado: 2022-12-29.
- [4] Jay Lee. Document classification using naive bayes method. <https://www.kaggle.com/code/jayaos/document-classification-using-naive-bayes-method/notebook>. Visitado: 2023-01-02.
- [5] Confusion matrix. https://en.wikipedia.org/wiki/Confusion_matrix. Visitado: 2023-01-03.